INSTITUTO POLITÉCTICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

UNIDAD DE APRENDIZAJE:

MACHINE LEARNING

PRÁCTICA 5: K-MEANS

INTEGRANTES:

Hernández Hernández Roberto Isaac

Gonzalez Llamosas Noe Ramses

PROFESOR:

Ortiz Castillo Marco Antonio

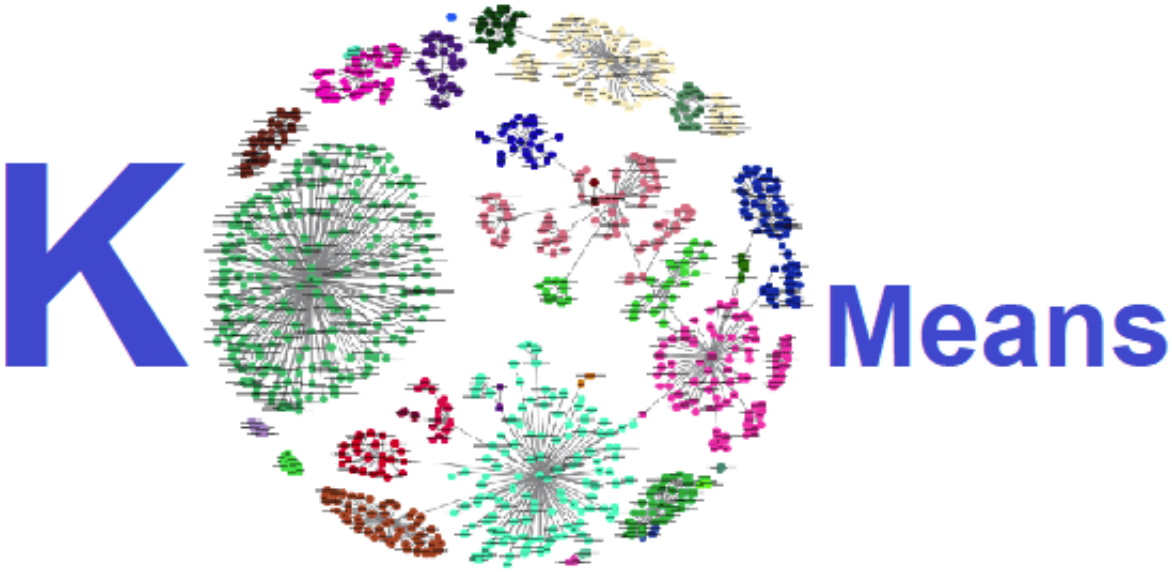

FECHA DE ENTREGA: 15/01/2025

CONTENIDO

1. PRÁCTICA: K-MEANS

1.1. INTRODUCCIÓN

K-means clustering es un algoritmo de aprendizaje no monitorear que se emplea para la agrupación de datos, que agrupa puntos de datos no etiquetados en grupos o clústeres. Es uno de los métodos de agrupación más populares utilizados en el machine learning. A diferencia del aprendizaje supervisado, los datos de entrenamiento que utiliza este algoritmo no están etiquetados, lo que significa que los puntos de datos no tienen una estructura de clasificación definida. Si bien existen varios tipos de algoritmos de agrupamiento, incluidos los exclusivos, superpuestos, jerárquicos y probabilísticos. Esta forma de agrupación estipula que un punto de datos puede existir en un solo clúster. Este tipo de análisis de clústeres se usa comúnmente en la ciencia de datos para la segmentación del mercado, la agrupación de documentos, la segmentación de imágenes y la compresión de imágenes. El algoritmo k-means es un método ampliamente empleado en el análisis de conglomerados porque es eficiente, eficaz y sencillo [1].

K-means es un algoritmo de agrupamiento iterativo basado en centroides que divide un conjunto de datos en grupos similares en función de la distancia entre sus centroides. El centroide, o centro del clúster, es la media o la mediana de todos los puntos dentro del clúster, según las características de los datos [1].

1.1.1. Funcionamiento del algoritmo

La agrupación en clústeres de K-means es un proceso iterativo para minimizar la suma de distancias entre los puntos de datos y sus centroides de clúster. El algoritmo de agrupamiento de medias k funciona categorizando puntos de datos en clústeres utilizando una medida matemática de distancia, generalmente euclidiana, desde el centro del clúster. El objetivo es minimizar la suma de distancias entre los puntos de datos y sus clústeres asignados. Los puntos de datos más cercanos a un centroide se agrupan dentro de la misma categoría. Un valor k más alto, o el número de conglomerados, significa conglomerados más pequeños con mayor detalle, mientras que un valor k más bajo da lugar a conglomerados más grandes con menos detalle [1].

- **Inicializar K:** El primer paso es inicializar k centroides donde k es igual al número de clústeres elegidos para un conjunto de datos específico. Este enfoque utiliza métodos de selección aleatoria o muestreo centroide inicial.
- **Asignar centroides:** El siguiente paso incluye un proceso iterativo de dos etapas basado en el algoritmo de machine learning de maximización de expectativas. El paso de expectativa asigna

cada punto de datos a su centroide más cercano en función de la distancia (de nuevo, normalmente euclídea). El paso de maximización calcula la media de todos los puntos de cada conglomerado y reasigna el centro del conglomerado, o centroide. Este proceso se repite hasta que las posiciones de los centroides hayan alcanzado la convergencia o se haya alcanzado el número máximo de iteraciones [1].

El agrupamiento de medias K es simple pero sensible a las condiciones iniciales y los valores atípicos. Es importante optimizar la inicialización del centroide y el número de clústeres k, para lograr los clústeres más significativos. Hay varias formas de evaluar y optimizar los componentes de agrupación del algoritmo mediante el uso de métricas de evaluación y métodos de muestreo de centroide inicial [1].

1.1.2. K-means ++

K-means++ es un algoritmo k-means que optimiza la selección del centroide o centroides iniciales del clúster. Desarrollado por los investigadores Arthur y Vassilvitskii, k-means++ mejora la calidad de la asignación final del clúster. El primer paso para la inicialización mediante el método de medias k++ es elegir un centroide del conjunto de datos. Para cada centroide subsiguiente, calcule la distancia de cada punto de datos desde su centro de clúster más cercano. El siguiente centroide se selecciona teniendo en cuenta la probabilidad de que un punto se encuentre a una distancia proporcional del centroide más cercano elegido anteriormente. El proceso ejecuta iteraciones hasta que se haya inicializado el número elegido de centros de clúster. En la siguiente figura se muestra la manera en que se clasifica de forma óptima un conjunto de datos mediante el K-means++.

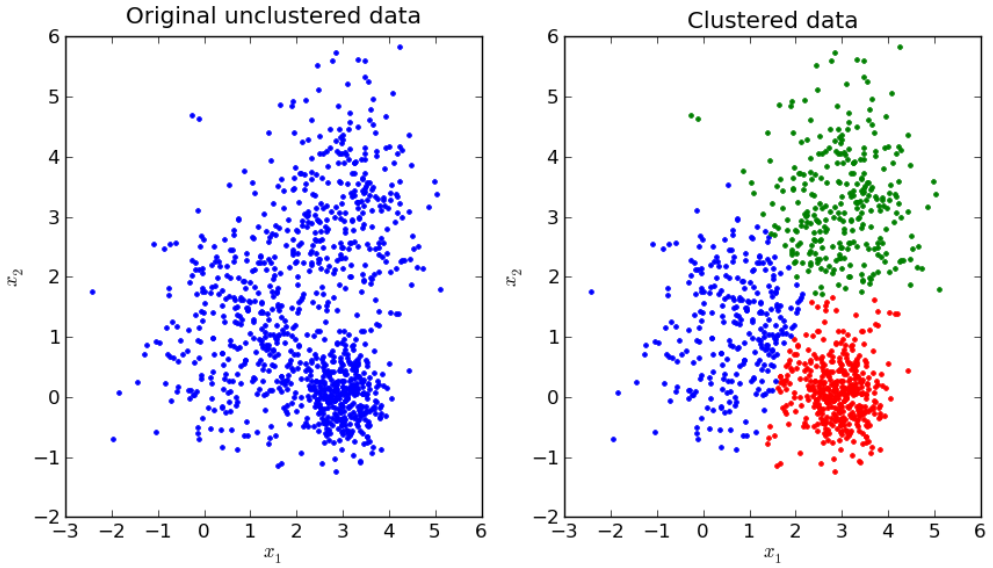

Figura. *Ejemplo de clasificación mediante K-means++. Fuente: [1].*

1.2. DESARROLLO

A manera de observar el comportamiento de este algoritmo es necesario implementar los siguientes puntos:

1. Crear 8 clases de puntos (20 puntos por clase) e implementar K-means, pruebe para diferentes valores de K.
2. Cambie el método de inicialización a K-means++ o considerando dispersión compare sus resultados con el punto anterior.
3. Sea el problema del titanic, realizar un programa que en cada muestra tenga las siguientes características $X_1(edad) - X_2(clase) - X_3(sexo)$ eligiendo K=2, determine para 100 muestras como se clasifica.

a) Diagrama de flujo

KMEANS

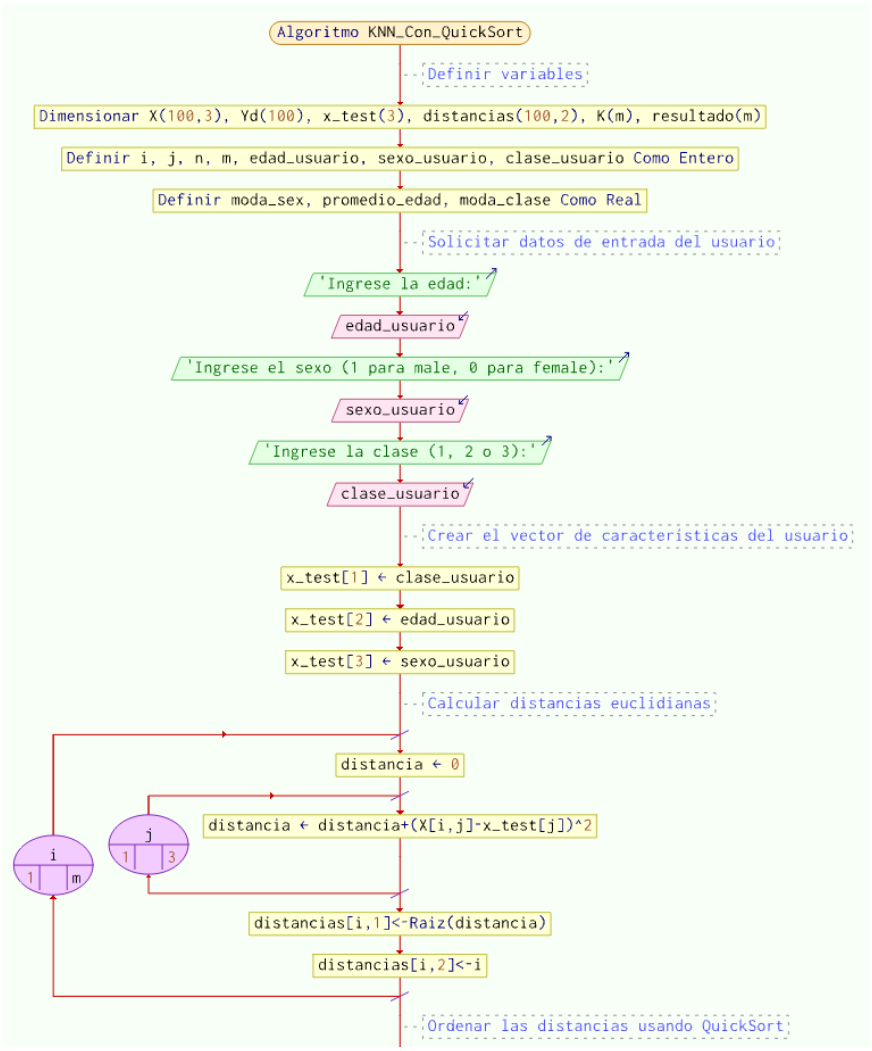

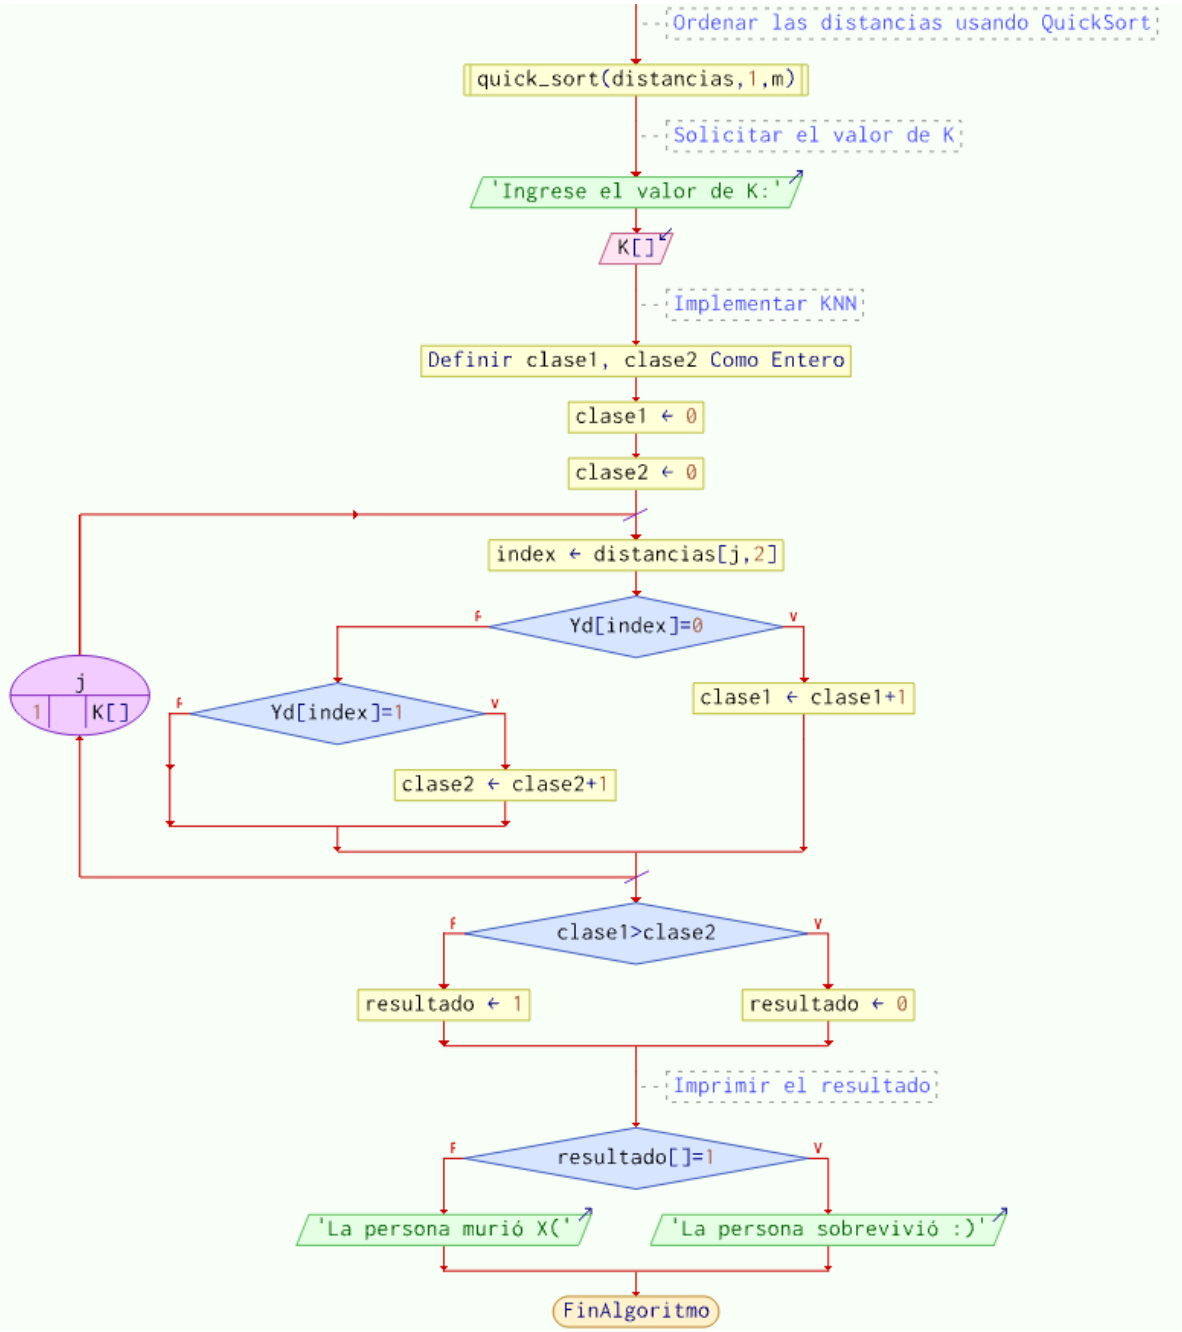
Ordenar las distancias usando QuickSort
quick_sort(distancias,1,m)
Solicitar el valor de K
'Ingrese el valor de K:'
K[]
Implementar KNN
Definir clase1, clase2 Como Entero
clase1 ← 0
clase2 ← 0
index ← distancias[j,2]
Yd[index]=0
F
V
clase1 ← clase1+1
Yd[index]=1
clase2 ← clase2+1
j
1
K[]
clase1>clase2
resultado ← 1
resultado ← 0
Imprimir el resultado
resultado[]=1
'La persona murió X('
'La persona sobrevivió :)'
FinAlgoritmo

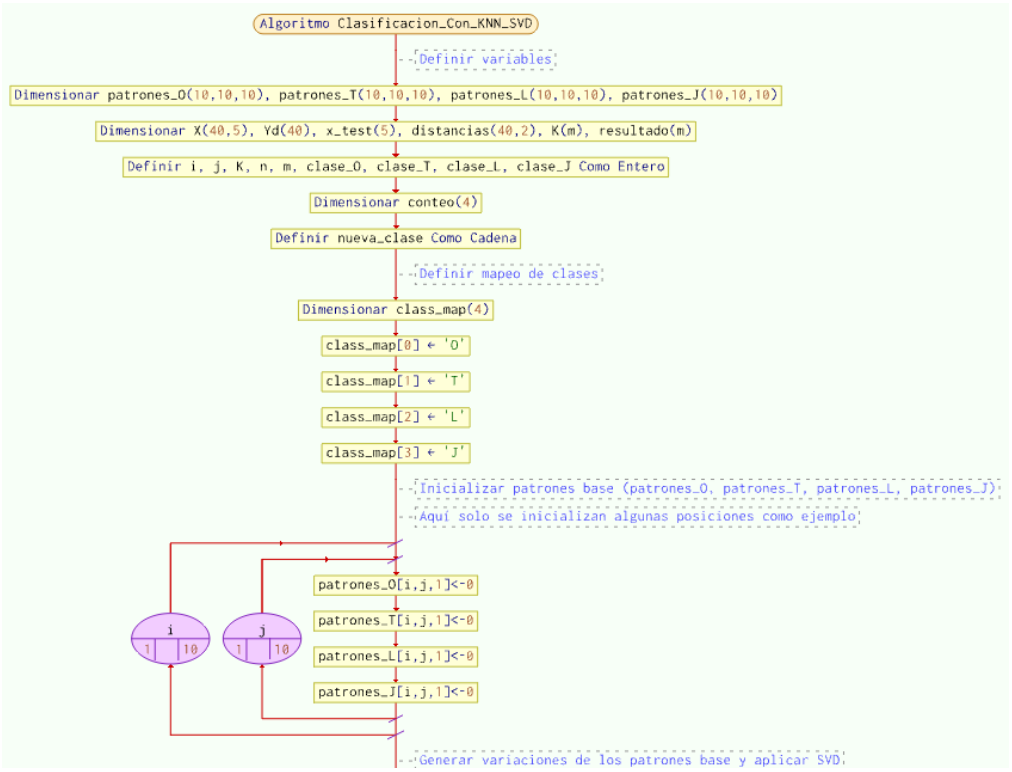
Algoritmo Clasificacion_Con_KNN_SVD
Definir variables
Dimensionar patrones_O(10,10,10), patrones_T(10,10,10), patrones_L(10,10,10), patrones_J(10,10,10)
Dimensionar X(40,5), Yd(40), x_test(5), distancias(40,2), K(m), resultado(m)
Definir i, j, K, n, m, clase_O, clase_T, clase_L, clase_J Como Entero
Dimensionar conteo(4)
Definir nueva_clase Como Cadena
Definir mapeo de clases
Dimensionar class_map(4)
class_map[0] ← 'O'
class_map[1] ← 'T'
class_map[2] ← 'L'
class_map[3] ← 'J'
Inicializar patrones base (patrones_O, patrones_T, patrones_L, patrones_J)
Aquí solo se inicializan algunas posiciones como ejemplo
i
1
10
j
1
10
patrones_O[i,j,1]<-0
patrones_T[i,j,1]<-0
patrones_L[i,j,1]<-0
patrones_J[i,j,1]<-0
Generar variaciones de los patrones base y aplicar SVD

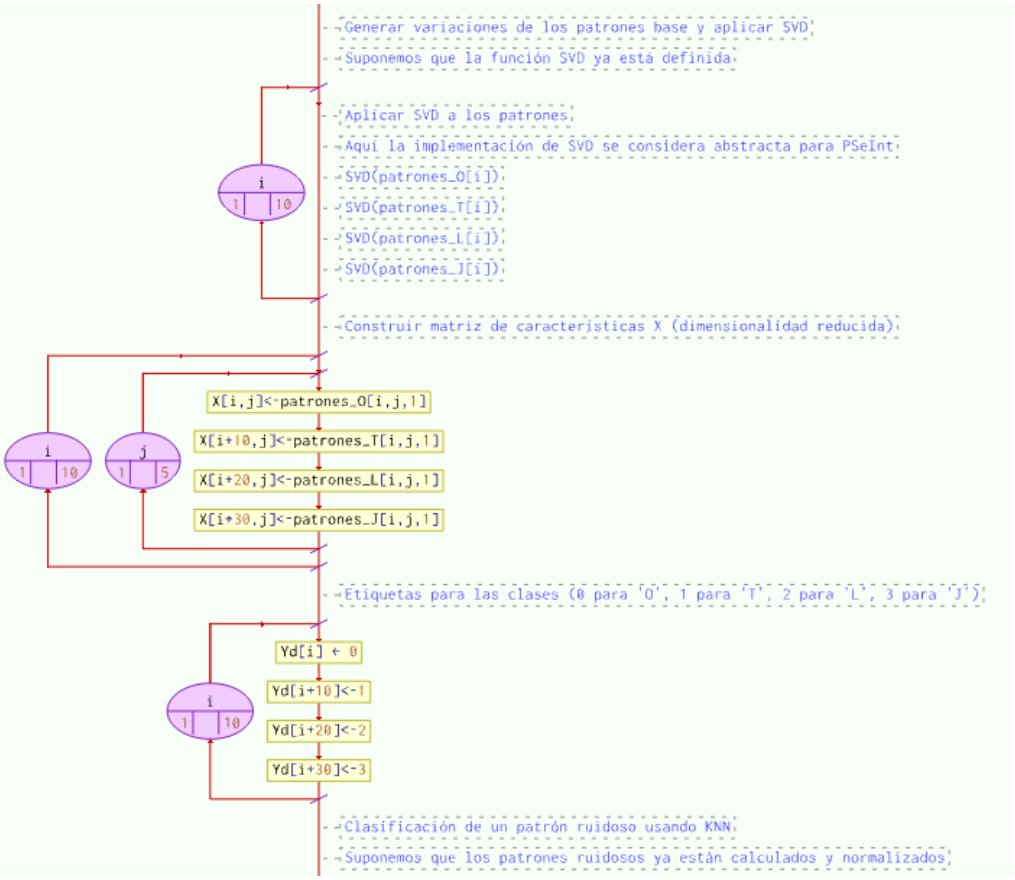
Generar variaciones de los patrones base y aplicar SVD
Suponemos que la función SVD ya está definida
Aplicar SVD a los patrones
Aquí la implementación de SVD se considera abstracta para PSeInt
i
1
10
SVD(patrones_O[i])
SVD(patrones_T[i])
SVD(patrones_L[i])
SVD(patrones_J[i])
Construir matriz de características X (dimensionalidad reducida)
i
1
10
j
1
5
X[i,j]<-patrones_O[i,j,1]
X[i+10,j]<-patrones_T[i,j,1]
X[i+20,j]<-patrones_L[i,j,1]
X[i+30,j]<-patrones_J[i,j,1]
Etiquetas para las clases (0 para 'O', 1 para 'T', 2 para 'L', 3 para 'J')
i
1
10
Yd[i] ← 0
Yd[i+10]<-1
Yd[i+20]<-2
Yd[i+30]<-3
Clasificación de un patrón ruidoso usando KNN
Suponemos que los patrones ruidosos ya están calculados y normalizados

b) Códigos

ALGORITMO KMEANS

```
import matplotlib.pyplot as plt
import random
import numpy as np

def distancia_ecluidiana(X, x_test):
    x_test = np.array(x_test)
    d = (X - x_test) ** 2
    distancia = [np.sqrt(d[i][0] + d[i][1]) for i in range(len(d))]
    return distancia

def Kmeans(data, k, epocas):
    data = np.array(data)
    num_datos, num_caracteristicas = data.shape

    # Inicializar aleatoriamente los centroides sin
duplicados    indices_usados = [-1] * k
    centroides = [[0] * num_caracteristicas for _ in range(k)]
    for i in range(k):
        while True:
            random_centroides = random.randint(0, num_datos - 1)
            if random_centroides not in indices_usados:
                indices_usados[i] = random_centroides
                for j in range(num_caracteristicas):
                    centroides[i][j] = data[random_centroides][j]
                break

    # Iteraciones para calcular los clústeres y actualizar los centroides
    for iteraciones in range(epocas):
        clouster_asignados = [0] * num_datos
        for i in range(num_datos):
            distancias = [distancia_ecluidiana([centroide], data[i])[0] for
centroide in centroides]
            clouster_asignados[i] = np.argmin(distancias)

        # Actualizar centroides
        Nuevos_Centroides = [[0] * num_caracteristicas for _ in range(k)]
        puntos_por_clouster = [0] * k
        for i in range(num_datos):
            clouster = clouster_asignados[i]
            puntos_por_clouster[clouster] += 1
            for j in range(num_caracteristicas):
                Nuevos_Centroides[clouster][j] += data[i][j]

        for clouster_index in range(k):
            if puntos_por_clouster[clouster_index] > 0:
                for j in range(num_caracteristicas):
                    Nuevos_Centroides[clouster_index][j] /=
puntos_por_clouster[clouster_index]
            else:
```

```
                for j in range(num_caracteristicas):
                    Nuevos_Centroides[clouster_index][j] =
centroides[clouster_index][j]

        # Verificar convergencia
        variacion = True
        epsilon = 1e-10
        for i in range(k):
            for j in range(num_caracteristicas):
                if abs(Nuevos_Centroides[i][j] - centroides[i][j]) >
epsilon:
                    variacion = False
                    break
            if not variacion:
                break
        if variacion:
            break

        centroides = Nuevos_Centroides

    # Agrupamiento final
    clousters= [[] for _ in range(k)]
    for i in range(num_datos):
        clousters[clouster_asignados[i]] = clousters[clouster_asignados[i]]
+ [data[i]]

    return centroides, clousters

def graficar_puntos(data, clousters, centroides):
    colors = ['red', 'blue', 'green', 'purple', 'orange', 'cyan', 'brown',
'magenta']
    for clouster_index in range(len(clousters)):
        x_points = [clousters[clouster_index][i][0] for i in
range(len(clousters[clouster_index]))]
        y_points = [clousters[clouster_index][i][1] for i in
range(len(clousters[clouster_index]))]
        plt.scatter(x_points, y_points, color=colors[clouster_index %
len(colors)], label=f'Clúster {clouster_index + 1}')
    x_centroides = [centroides[i][0] for i in range(len(centroides))]
    y_centroides = [centroides[i][1] for i in range(len(centroides))]
    plt.scatter(x_centroides, y_centroides, color='black', marker='x',
s=100, label='Centroides')
    plt.xlabel("x-axis")
    plt.ylabel("y-axis")
    plt.title("K-means")
    plt.legend()
    plt.grid(True)
    plt.show()

# Datos de prueba
data = [
    # Clase 1: Alrededor de (-50, -50)
```

```
    [random.uniform(-55, -35), random.uniform(-55, -35)] for _ in range(20)
] + [
    # Clase 2: Alrededor de (-20, 20)
    [random.uniform(-25, -5), random.uniform(15, 35)] for _ in range(20)
] + [
    # Clase 3: Alrededor de (0, -30)
    [random.uniform(-5, 15), random.uniform(-35, -15)] for _ in range(20)
] + [
    # Clase 4: Alrededor de (40, 40)
    [random.uniform(35, 55), random.uniform(35, 55)] for _ in range(20)
] + [
    # Clase 5: Alrededor de (60, -60)
    [random.uniform(55, 75), random.uniform(-65, -45)] for _ in range(20)
] + [
    # Clase 6: Alrededor de (-70, 70)
    [random.uniform(-75, -55), random.uniform(65, 85)] for _ in range(20)
] + [
    # Clase 7: Alrededor de (80, 10)
    [random.uniform(75, 95), random.uniform(5, 25)] for _ in range(20)
] + [
    # Clase 8: Alrededor de (-90, -90)
    [random.uniform(-95, -75), random.uniform(-95, -75)] for _ in range(20)
]

k = 8
epocas = 100
centroides, clousters = Kmeans(data, k, epocas)
graficar_puntos(data, clousters, centroides)
```

ALGORITMO KMEANS++

```
import matplotlib.pyplot as plt
import random
import numpy as np

def distancia_ecluidiana(X, x_test):
    x_test = np.array(x_test)
    d = (X - x_test) ** 2
    distancia = [np.sqrt(d[i][0] + d[i][1]) for i in range(len(d))]
    return distancia

def inicializar_centroides(data, k):
    data = np.array(data)
    num_datos = len(data)

    # Inicializar el array de centroides con tamaño k x num_caracteristicas
    num_caracteristicas = data.shape[1]
    centroides = np.zeros((k, num_caracteristicas))

    # Seleccionar el primer centroide al azar
    primer_centroide_idx = random.randint(0, num_datos - 1)
    centroides[0] = data[primer_centroide_idx]
```

```
    for i in range(1, k):
        # Calcular las distancias mínimas al conjunto actual de centroides
        distancias_minimas = np.zeros(len(data))  # Crear un array
inicializado con ceros
        for idx, punto in enumerate(data):
            distancias = [np.linalg.norm(punto - centroides[j]) for j in
range(i)]
            distancias_minimas[idx] = min(distancias)  # Asignar el mínimo
directamente al índice correspondiente

        # Elegir el siguiente centroide con probabilidad proporcional al
cuadrado de la distancia
        distancias_cuadradas = distancias_minimas ** 2
        probabilidades = distancias_cuadradas / distancias_cuadradas.sum()
        siguiente_centroide_idx = np.random.choice(range(len(data)),
p=probabilidades)
        centroides[i] = data[siguiente_centroide_idx]

    return centroides

def Kmeans(data, k, epocas):
    data = np.array(data)
    num_datos, num_caracteristicas = data.shape

    # Inicializar centroides usando K-Means++
    centroides = inicializar_centroides(data, k)

    # Iteraciones para calcular los clústeres y actualizar los centroides
    for iteraciones in range(epocas):
        clouster_asignados = [0] * num_datos
        for i in range(num_datos):
            distancias = [distancia_ecluidiana([centroide], data[i])[0] for
centroide in centroides]
            clouster_asignados[i] = np.argmin(distancias)

        # Actualizar centroides
        Nuevos_Centroides = [[0] * num_caracteristicas for _ in range(k)]
        puntos_por_clouster = [0] * k
        for i in range(num_datos):
            clouster = clouster_asignados[i]
            puntos_por_clouster[clouster] += 1
            for j in range(num_caracteristicas):
                Nuevos_Centroides[clouster][j] += data[i][j]

        for clouster_index in range(k):
            if puntos_por_clouster[clouster_index] > 0:
                for j in range(num_caracteristicas):
                    Nuevos_Centroides[clouster_index][j] /=
puntos_por_clouster[clouster_index]
            else:
                for j in range(num_caracteristicas):
```

```
                    Nuevos_Centroides[clouster_index][j] =
centroides[clouster_index][j]

        # Verificar convergencia
        variacion = True
        epsilon = 1e-10
        for i in range(k):
            for j in range(num_caracteristicas):
                if abs(Nuevos_Centroides[i][j] - centroides[i][j]) >
epsilon:
                    variacion = False
                    break
            if not variacion:
                break
        if variacion:
            break

        centroides = Nuevos_Centroides

    # Agrupamiento final
    clousters = [[] for _ in range(k)]
    for i in range(num_datos):
        clousters[clouster_asignados[i]] = clousters[clouster_asignados[i]]
+ [data[i]]

    return centroides, clousters

def graficar_puntos(data, clousters, centroides):
    colors = ['red', 'blue', 'green', 'purple', 'orange', 'cyan', 'brown',
'magenta']
    for clouster_index in range(len(clousters)):
        x_points = [clousters[clouster_index][i][0] for i in
range(len(clousters[clouster_index]))]
        y_points = [clousters[clouster_index][i][1] for i in
range(len(clousters[clouster_index]))]
        plt.scatter(x_points, y_points, color=colors[clouster_index %
len(colors)], label=f'Clúster {clouster_index + 1}')
    x_centroides = [centroides[i][0] for i in range(len(centroides))]
    y_centroides = [centroides[i][1] for i in range(len(centroides))]
    plt.scatter(x_centroides, y_centroides, color='black', marker='x',
s=100, label='Centroides')
    plt.xlabel("x-axis")
    plt.ylabel("y-axis")
    plt.title("K-means++")
    plt.legend()
    plt.grid(True)
    plt.show()


# Datos de prueba dispersos
data = [
    # Clase 1: Alrededor de (-50, -50)
```

```
    [random.uniform(-55, -35), random.uniform(-55, -35)] for _ in range(20)
] + [
    # Clase 2: Alrededor de (-20, 20)
    [random.uniform(-25, -5), random.uniform(15, 35)] for _ in range(20)
] + [
    # Clase 3: Alrededor de (0, -30)
    [random.uniform(-5, 15), random.uniform(-35, -15)] for _ in range(20)
] + [
    # Clase 4: Alrededor de (40, 40)
    [random.uniform(35, 55), random.uniform(35, 55)] for _ in range(20)
] + [
    # Clase 5: Alrededor de (60, -60)
    [random.uniform(55, 75), random.uniform(-65, -45)] for _ in range(20)
] + [
    # Clase 6: Alrededor de (-70, 70)
    [random.uniform(-75, -55), random.uniform(65, 85)] for _ in range(20)
] + [
    # Clase 7: Alrededor de (80, 10)
    [random.uniform(75, 95), random.uniform(5, 25)] for _ in range(20)
] + [
    # Clase 8: Alrededor de (-90, -90)
    [random.uniform(-95, -75), random.uniform(-95, -75)] for _ in range(20)
]

k = 8
epocas = 100
centroides, clousters = Kmeans(data, k, epocas)
graficar_puntos(data, clousters, centroides)
```

ALGORITMO KMEANS++ PARA PROBLEMÁTICA DEL TITANIC

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

def entrenamiento_MSV(X, Y):
    numero_muestras, numero_caracteristicas = X.shape

    # Inicialización parámetros externos
    epocas = 1000
    lr = 0.01
    lamda = 1 / epocas

    # Inicialización de parámetros internos
    w = np.zeros(numero_caracteristicas) + 0.1
    b = 0.1

    for epoca in range(epocas):
        for i, x in enumerate(X):
            condicion_margen = Y[i] * (np.dot(x, w) + b) >= 1
            if condicion_margen:
                w = w - lr * (2 * lamda * w)
```

```
            else:
                w = w - lr * (2 * lamda * w - np.dot(Y[i], x))
                b = b - lr * lamda * Y[i]

    tolerancia = 1
    vectores_soporte_indices = [
        i for i, x in enumerate(X)
        if abs(Y[i] * (np.dot(x, w) + b) - 1) <= tolerancia
    ]
    vectores_soporte = X[vectores_soporte_indices]
    clases_vectores_soporte = Y[vectores_soporte_indices]

    return w, b, vectores_soporte, vectores_soporte_indices,
clases_vectores_soporte

def prediccion_MSV(X_test, w, b):
    return np.sign(np.dot(X_test, w) + b)

# Cargar los datos
ruta_archivo = './train.csv'
datos = pd.read_csv(ruta_archivo)

Y = datos['Survived'].tolist()
vivos = [y for y in Y if y == 1][:30]
muertos = [y for y in Y if y == 0][:30]
Y_fixed = np.array(vivos + muertos)

indices_vivos = [i for i, y in enumerate(Y) if y == 1][:30]
indices_muertos = [i for i, y in enumerate(Y) if y == 0][:30]
indices_filtrados = indices_vivos + indices_muertos

SibSp = datos['SibSp'].tolist()
Age = datos['Age'].tolist()
Pclass = datos['Pclass'].tolist()

moda_sibsp = max(set(SibSp), key=SibSp.count)
SibSp = [moda_sibsp if pd.isna(s) else s for s in SibSp]
SibSp = [moda_sibsp if s < 0 or not isinstance(s, int) else s for s in
SibSp]
SibSp = [int(s) for s in SibSp]

Age = [np.nan if pd.isna(a) else a for a in Age]
promedio_edad = np.nanmean(Age)
Age = [promedio_edad if np.isnan(a) else a for a in Age]

moda_clase = max(set(Pclass), key=Pclass.count)
Pclass = [moda_clase if pd.isna(c) else c for c in Pclass]
Pclass = [int(c) for c in Pclass]

X = np.array(list(zip(Pclass, Age, SibSp)))
X_fixed = X[indices_filtrados]
```

```
w, b, vectores_soporte, vectores_soporte_indices, clases_vectores_soporte =
entrenamiento_MSV(X_fixed, Y_fixed)

nuevo_punto = []
nuevo_punto.append(int(input("Ingrese la clase de pasajero (Pclass, 1-3):
")))
nuevo_punto.append(float(input("Ingrese la edad del pasajero: ")))
nuevo_punto.append(int(input("Ingrese el número de hermanos/esposos (SibSp):
")))
nuevo_punto = np.array(nuevo_punto)
clase_predicha = prediccion_MSV(nuevo_punto, w, b)

print(f"El nuevo punto pertenece a la clase: {'Sobrevivió' if clase_predicha
== 1 else 'No sobrevivió'}")

print("Vectores de soporte:")
for i, vector in enumerate(vectores_soporte):
    print(f"Vector: {vector}, Clase: {clases_vectores_soporte[i]}")

fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.scatter(X_fixed[:, 0], X_fixed[:, 1], X_fixed[:, 2], c=Y_fixed,
cmap=plt.cm.Paired, label='Datos')

ax.scatter(X_fixed[vectores_soporte_indices, 0],
           X_fixed[vectores_soporte_indices, 1],
           X_fixed[vectores_soporte_indices, 2],
           s=150, facecolors='yellow', edgecolors='red', linewidths=2,
label='Vectores de Soporte')

ax.scatter(nuevo_punto[0], nuevo_punto[1], nuevo_punto[2],
           color='green', marker='o', s=150, label='Nuevo punto')

# Hiperplano y márgenes
xx, yy = np.meshgrid(np.linspace(X_fixed[:, 0].min(), X_fixed[:, 0].max(),
10),
                     np.linspace(X_fixed[:, 1].min(), X_fixed[:, 1].max(),
10))
zz = (-w[0] * xx - w[1] * yy - b) / w[2]
ax.plot_surface(xx, yy, zz, alpha=0.3, color='blue', label='Hiperplano')

ax.set_xlabel('Pclass')
ax.set_ylabel('Age')
ax.set_zlabel('SibSp')
plt.title('Máquinas de Soporte Vectorial (MSV)')
plt.legend()
plt.show()
```

c) Funcionamiento

ALGORITMO KMEANS

Los resultados obtenidos tras la implementación del algoritmo K-means, considerando 8 clases distintas, cada una compuesta por 20 puntos y utilizando un valor de K=8, se presentan en la figura siguiente. Es importante analizar la distribución de los centroides, ya que su inicialización aleatoria puede conducir a la formación de clústeres de manera subóptima.

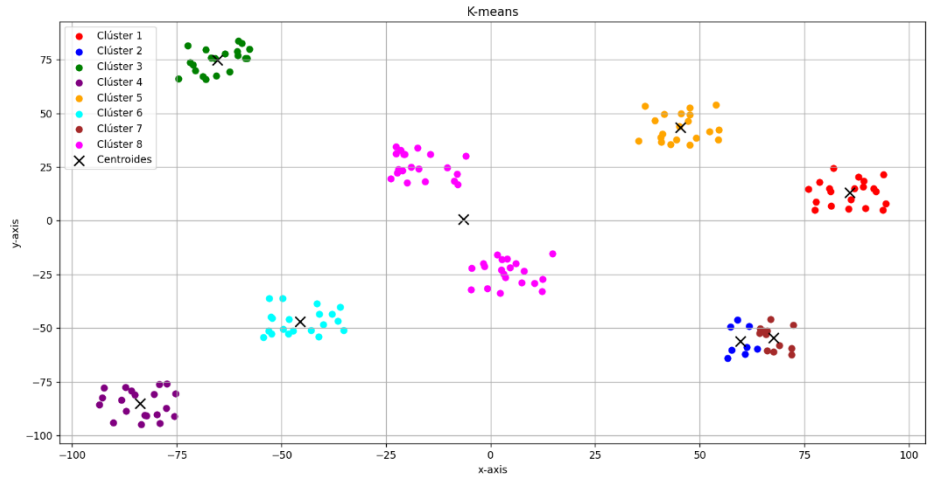

Figura. *Clasificación del algoritmo para un K=8. Fuente: Elaboración propia.*

Con el propósito de realizar múltiples pruebas con el algoritmo, se muestra su ejecución para un K=5 y un K=3. Los resultados se muestran a continuación.

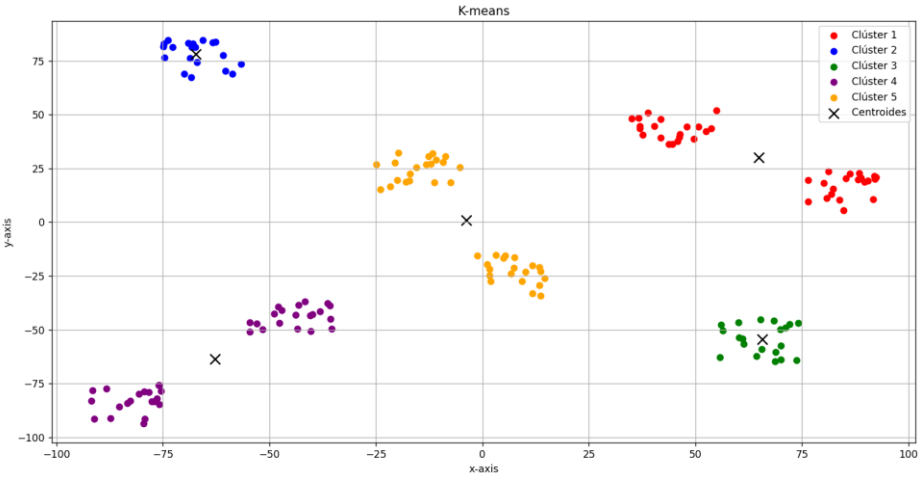

Figura. *Clasificación del algoritmo para un K=5. Fuente: Elaboración propia.*

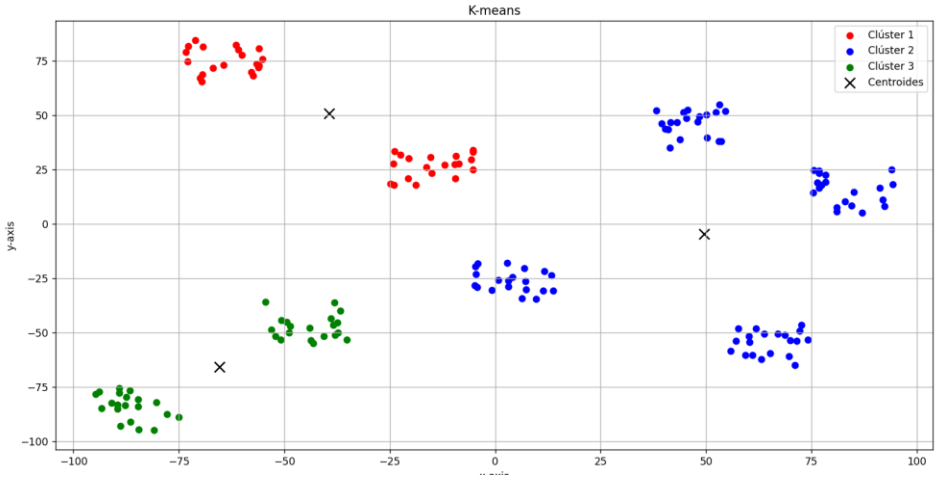

Figura. *Clasificación del algoritmo para un K=3. Fuente: Elaboración propia.*

ALGORITMO KMEANS++

En nuestro caso, optamos por implementar el algoritmo K-means++ para lograr una clasificación más precisa de cada una de las clases creadas. Asimismo, realizamos pruebas utilizando diferentes valores de K con el objetivo de analizar el comportamiento del algoritmo en distintos escenarios. En este caso, es crucial observar cómo el algoritmo realiza la clasificación de manera adecuada, asignando un clúster distinto a cada grupo creado.

Como se menciona en la introducción, este algoritmo selecciona el siguiente centroide de los puntos de datos de modo que la probabilidad de elegir un punto como centroide sea directamente proporcional a su distancia desde el centroide más cercano previamente elegido (es decir, el punto que tenga la distancia máxima desde el centroide más cercano tenga más probabilidades de ser seleccionado a continuación como centroide).

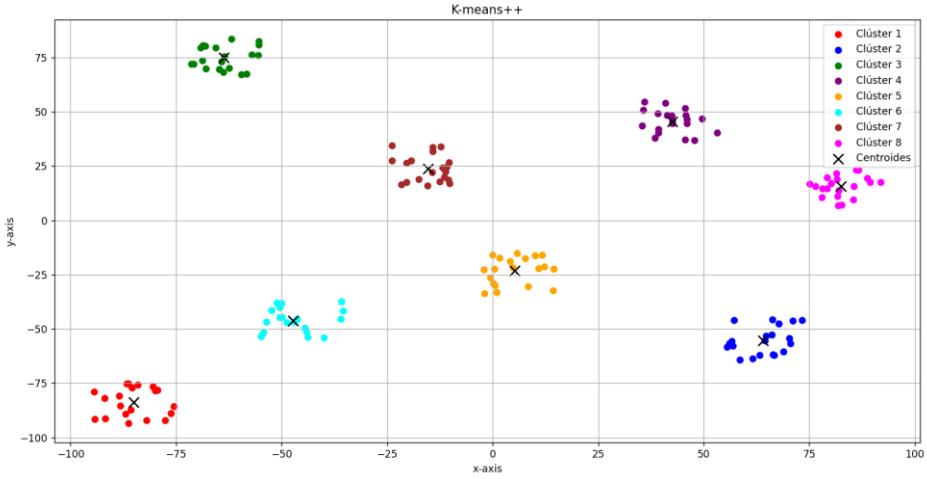

Figura. *Clasificación del algoritmo para un K=8. Fuente: Elaboración propia.*

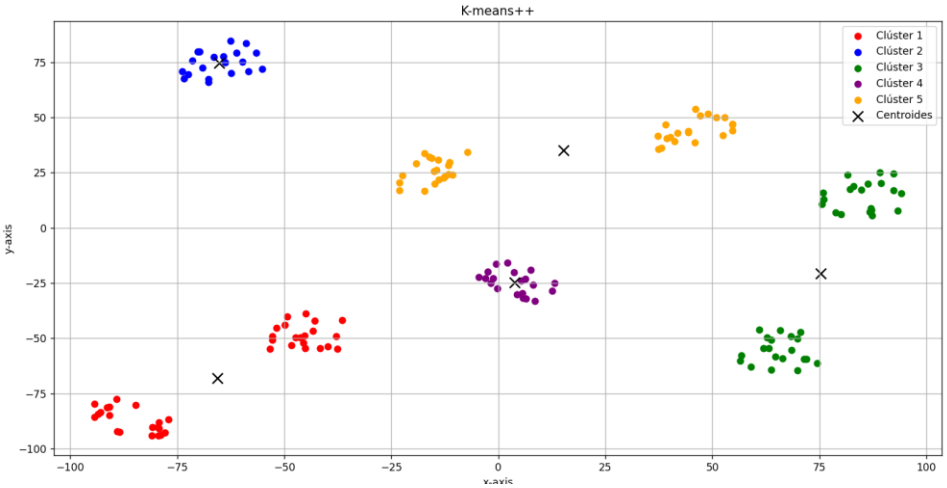

Figura. *Clasificación del algoritmo para un K=5. Fuente: Elaboración propia.*

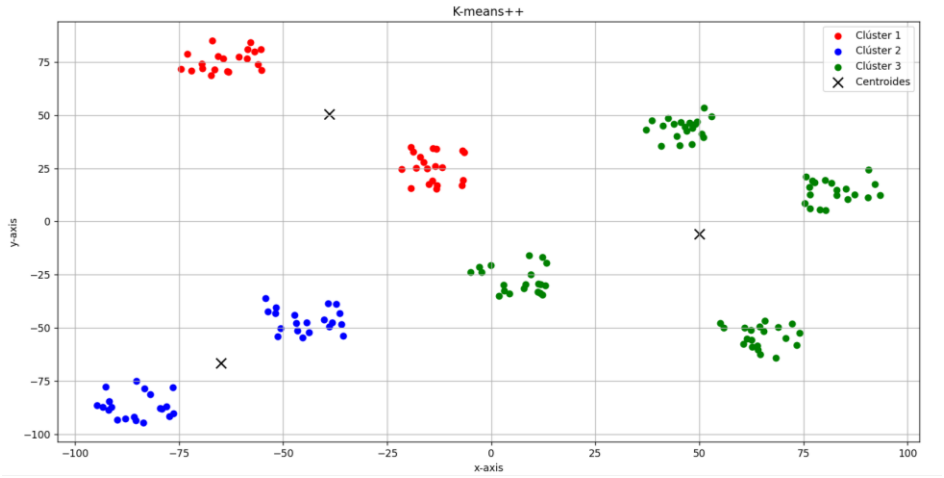

Figura. *Clasificación del algoritmo para un K=3. Fuente: Elaboración propia.*

ALGORITMO KMEANS++ PARA PROBLEMÁTICA DEL TITANIC

Para resolver este ejercicio, se empleó el algoritmo K-means++, basándose en la implementación realizada en prácticas anteriores con el archivo CSV del Titanic. En este archivo, los datos fueron procesados y depurados adecuadamente para su uso. Además, se solicitó al usuario ingresar una clase, edad y sexo, permitiendo que el algoritmo determine si el nuevo punto ingresado pertenece a la categoría de sobrevivientes o fallecidos. En nuestro caso, se presenta únicamente uno de los dos clústeres, indicando la cantidad de datos asignados durante el entrenamiento.

Fue fundamental considerar una grafica tridimensional para mostrar las características y la clasificación de forma adecuada, de esta manera es posible interpretar la relación entre las variables de entrada (como clase, edad y sexo) de manera más clara y comprensible.

En las siguientes figuras se presenta de manera gráfica y en la terminal el resultado de la clasificación realizada, mostrando un ejemplo de una persona que sobrevivió y otro de una que falleció.

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS  GITLENS  COMMENTS

PS C:\Users\gonza\OneDrive\Documentos\Octavo Semestre\Machine Learning> python titanic-kmeans++.py
Ingrese la clase de pasajero (Pclass, 1-3): 3
Ingrese la edad del pasajero: 90
Ingrese el sexo del pasajero (0 para mujer, 1 para hombre): 1
El pasajero sobrevivió.
```

Figura. *Resultado en terminal de un pasajero fallecido. Fuente: Elaboración propia.*

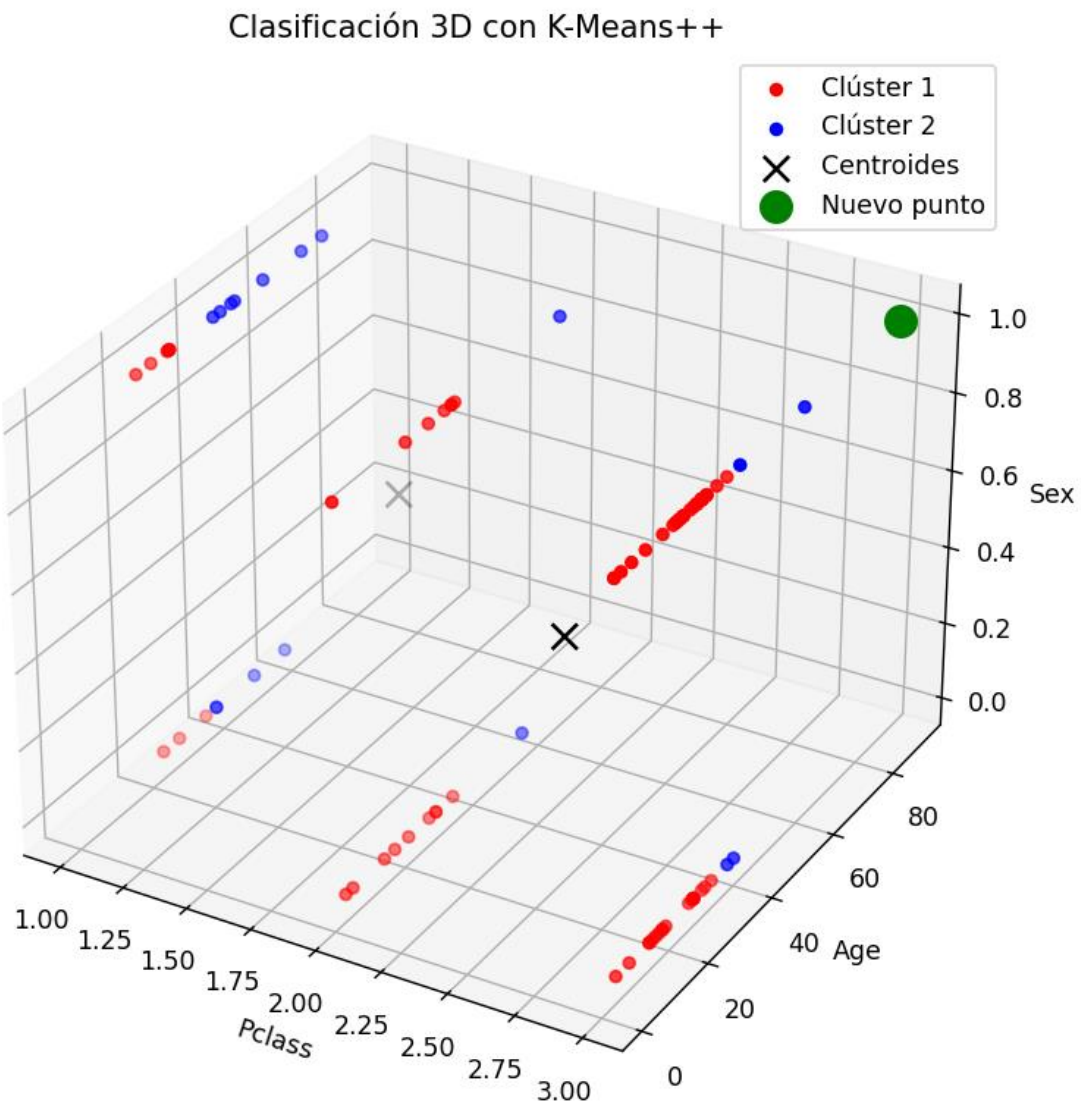

Figura. *Resultado en gráfica 3D de un pasajero fallecido. Fuente: Elaboración propia.*

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS  GITLENS  COMMENTS

PS C:\Users\gonza\OneDrive\Documentos\Octavo Semestre\Machine Learning> python titanic-kmeans++.py
Ingrese la clase de pasajero (Pclass, 1-3): 1
Ingrese la edad del pasajero: 4
Ingrese el sexo del pasajero (0 para mujer, 1 para hombre): 0
El pasajero sobrevivió.
```

Figura. *Resultado en terminal de un pasajero que sobrevivió. Fuente: Elaboración propia.*

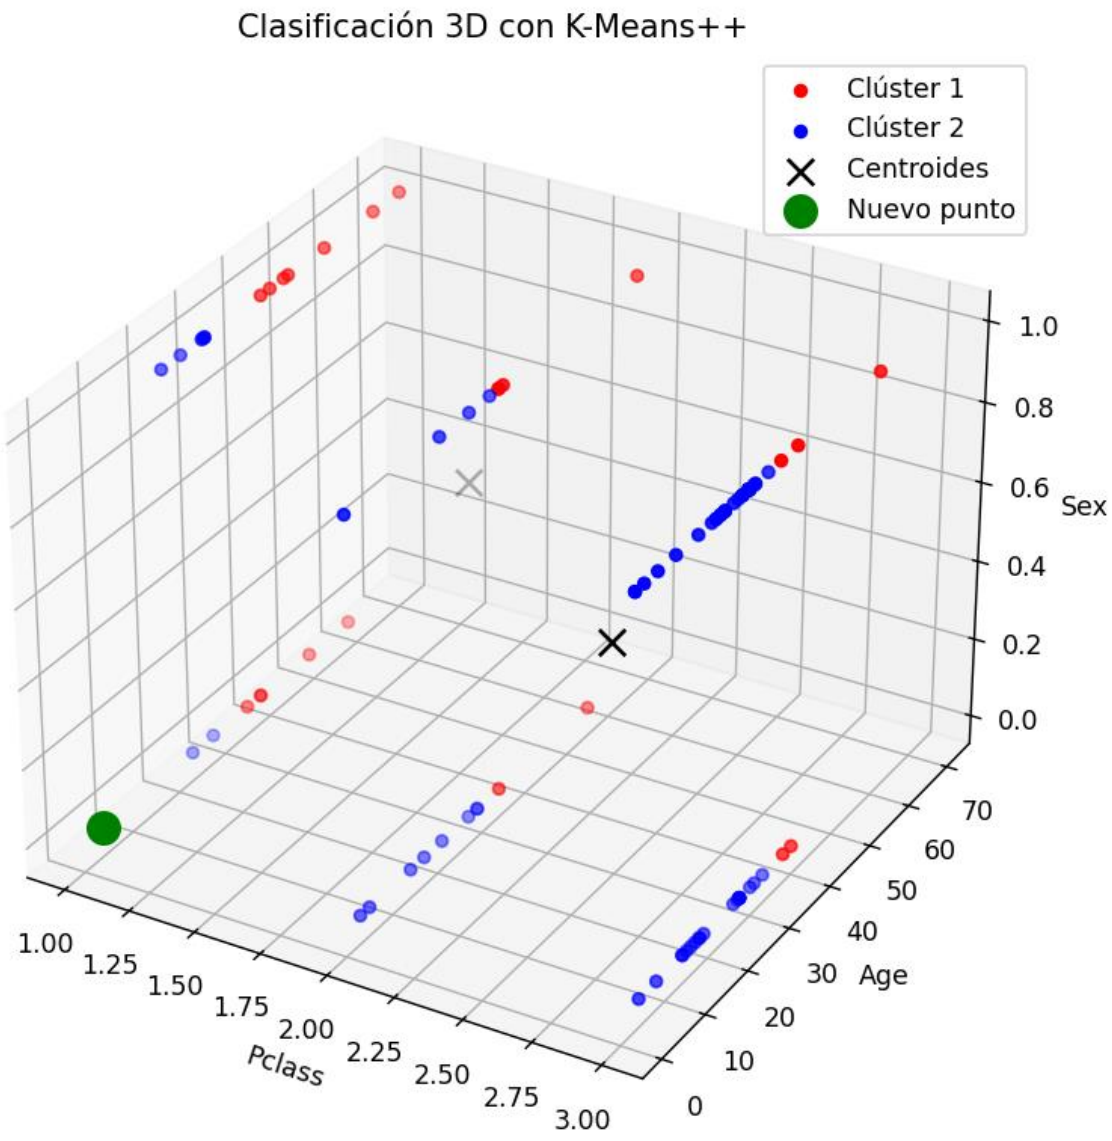

Figura. *Resultado en gráfica 3D de un pasajero que sobrevivió. Fuente: Elaboración propia.*

1.3. CONCLUSIÓN

En el caso del algoritmo K-means, tanto en su versión estándar como en la versión K-means++, la visualización de los datos juega un papel crucial para que el programador pueda determinar el número adecuado de centroides (K). Una elección incorrecta de este valor puede afectar significativamente la calidad de la clasificación, incluso en la versión mejorada del algoritmo, K-means++.

Un ejemplo claro de esta situación se presenta cuando se selecciona un K=3. Aunque el algoritmo intenta realizar una clasificación óptima con esta cantidad de centroides, el resultado puede no ser el más adecuado para los datos disponibles. En este caso, un análisis visual previo podría indicar la necesidad de aumentar el número de centroides para reflejar de manera más precisa la distribución y estructura de los datos. Esto resalta la importancia de combinar el análisis visual con la lógica del algoritmo para maximizar la eficiencia de la clasificación y evitar posibles conflictos derivados de una mala parametrización.

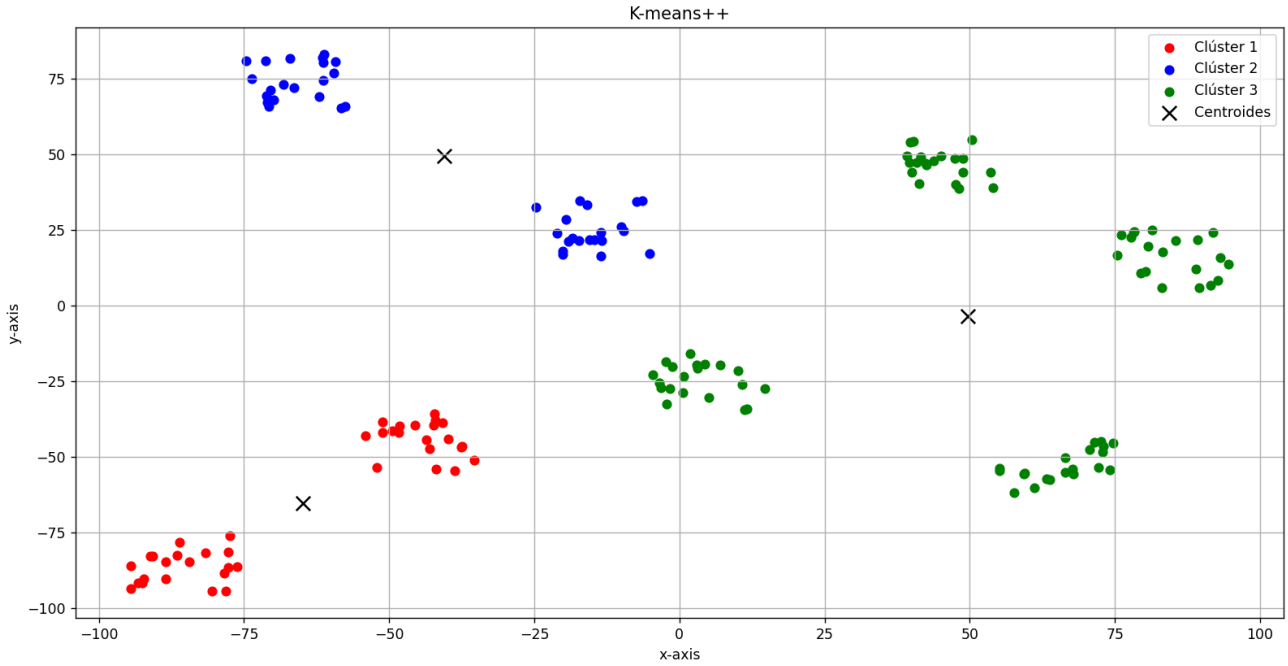

Figura. *Ejemplo de una mala inicialización de centroides. Fuente: Elaboración propia.*

Para este caso lo adecuado sería aumentar la cantidad de K a 8 como en el caso óptimo que lo utilizamos en la parte del desarrollo, esto se infiere desde el análisis de la forma en que se encuentran dispersos los datos.

INSTITUTO POLITÉCTICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

UNIDAD DE APRENDIZAJE:

MACHINE LEARNING

PRÁCTICA 6: MÁQUINAS DE SOPORTE VECTORIAL

INTEGRANTES:

Hernández Hernández Roberto Isaac

Gonzalez Llamosas Noe Ramses

PROFESOR:

Ortiz Castillo Marco Antonio

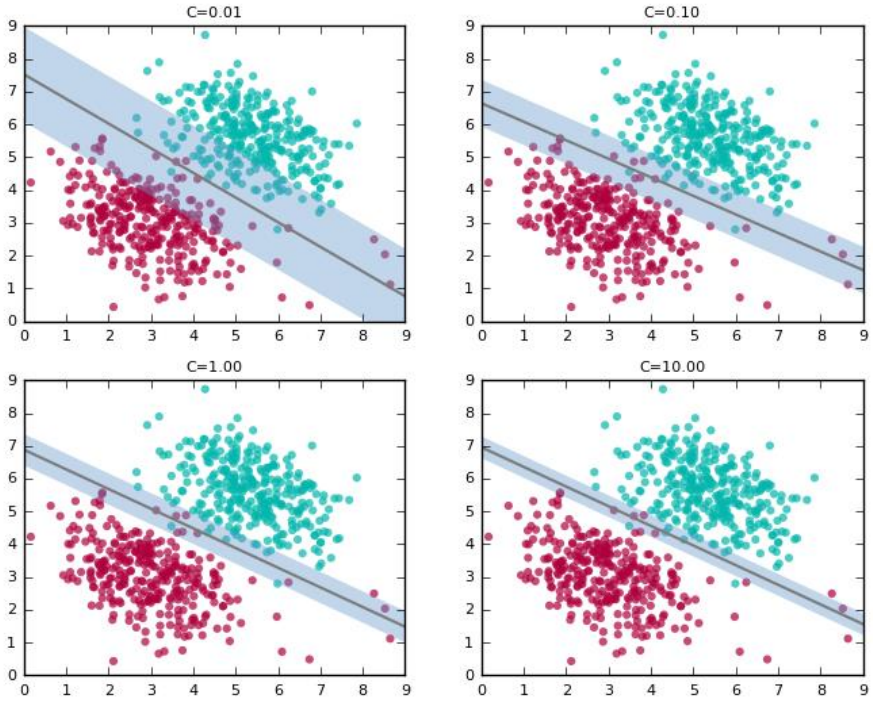

FECHA DE ENTREGA: 15/01/2025

2. PRÁCTICA: SUPPORT VECTOR MACHINE

2.1. INTRODUCCIÓN

La máquina de vectores de soporte (SVM) es un algoritmo de clasificación y regresión que utiliza la teoría de aprendizaje de las máquinas para maximizar la precisión de las predicciones sin ajustar excesivamente los datos. SVM utiliza una transformación no lineal opcional de los datos de entrenamiento, seguida de la búsqueda de ecuaciones de regresión en los datos transformados para separar las clases (para objetivos categóricos) o ajustar el objetivo (para los objetivos continuos). La implementación de SVM de Oracle permite que se generen modelos mediante el uso de los dos kernels disponibles: lineal o gaussiano. El kernel lineal omite la transformación no lineal de una vez, de tal forma que el modelo resultante sea, en esencia, un modelo de regresión [2].

Es un algoritmo de aprendizaje automático supervisado que se puede utilizar para problemas de clasificación o regresión. Pero generalmente se usa para clasificar. Dadas 2 o más clases de datos etiquetadas, actúa como un clasificador discriminativo, definido formalmente por un hiperplano óptimo que separa todas las clases. Los nuevos ejemplos que luego se mapean en ese mismo espacio se pueden clasificar según el lado de la brecha en que se encuentran. Los vectores de soporte son los puntos de datos más cercanos al hiperplano, los puntos de un conjunto de datos que, si se eliminan, alterarían la posición del hiperplano en división. Debido a esto, pueden considerarse los elementos críticos de un conjunto de datos, son los que nos ayudan a construir nuestra SVM [3]. En la siguiente figura se muestra la representación de vectores de soporte en SVM.

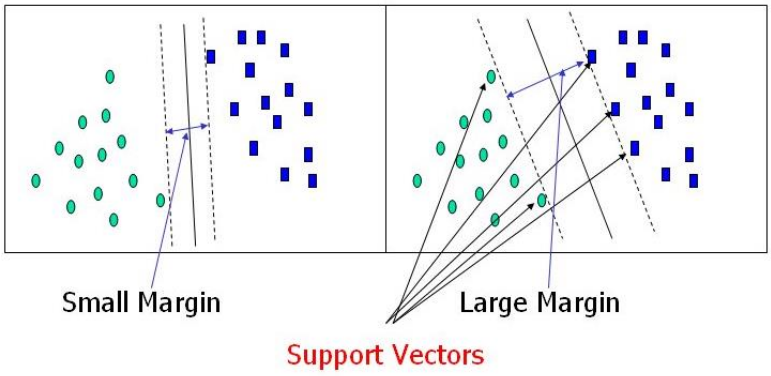

Figura. *Representación de vectores de soporte. Fuente: [3].*

La geometría nos dice que un hiperplano es un subespacio de una dimensión menos que su espacio ambiental. Por ejemplo, un hiperplano de un espacio n-dimensional es un subconjunto plano con dimensión $n - 1$. Por su naturaleza, separa el espacio en dos medios espacios [3].

2.1.1. Funcionamiento de las SVM

Los conceptos básicos de Support Vector Machines y su funcionamiento se comprenden mejor con un ejemplo sencillo. Imaginemos que tenemos dos etiquetas: *rojos* y *azules*, y nuestros datos tiene dos características: *x* e *y*. Queremos un clasificador que, dado un par de coordenadas *(x, y)*, dé como resultado si es *rojo* o *azul*. Trazamos nuestros datos de entrenamiento ya etiquetados en un avión:

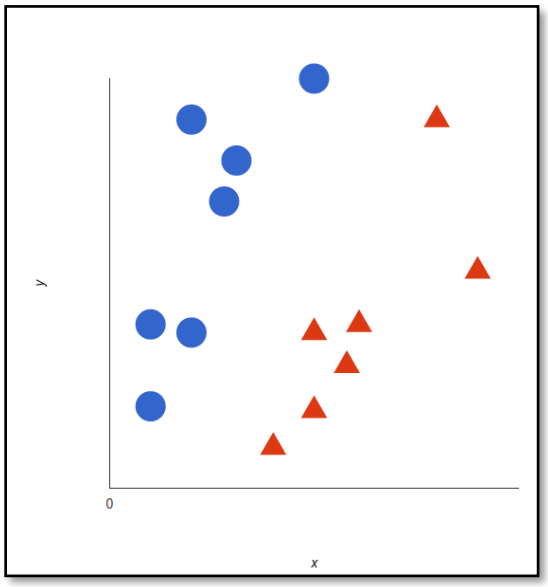

Figura. *Datos etiquetados. Fuente: [3].*

Una máquina de vectores de soporte toma estos puntos de datos y genera el hiperplano (que en dos dimensiones es simplemente una línea) que separa mejor las etiquetas. Esta línea es el **límite de decisión**: todo lo que caiga a un lado lo clasificaremos como *azul* y todo lo que caiga al otro lado como *rojo*.

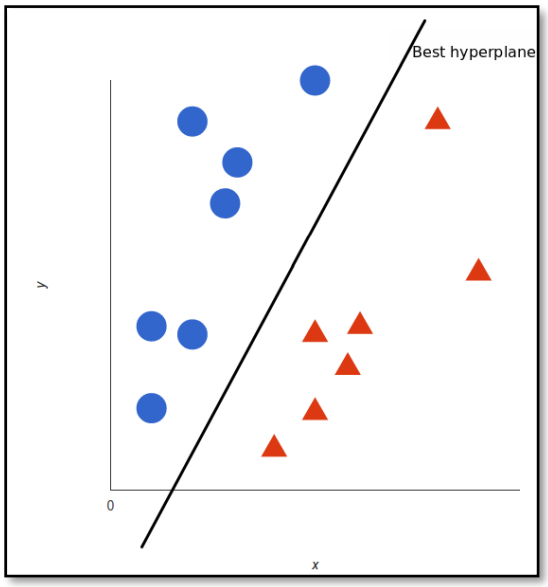

Figura. *Hiperplano. Fuente: [3].*

2.2. DESARROLLO

- Para comprender el funcionamiento de este algoritmo, tomar 3 características del archivo CSV del Titanic (Edad, Clase, SipSp) y aplicando MSV realizar la clasificación con un entrenamiento equilibrado (30 vivos y 30 muertos).
- Retomar los patrones ruidosos (20 por clase) (2 clases), ± 0.1 de ruido. Aplicar SVD, entrenar el modelo MSV y considerando 4 patrones nuevos (2 para cada clase) realizar la clasificación.

a) Códigos

```
ALGORITMO SVM CON PROBLEMÁTICA DEL TITANIC
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

def entrenamiento_MSV(X, Y):
    numero_muestras, numero_caracteristicas = X.shape

    # Inicialización parámetros externos
    epocas = 1000
    lr = 0.01
    lamda = 1 / epocas

    # Inicialización de parámetros internos
    w = np.zeros(numero_caracteristicas) + 0.1
    b = 0.1

    for epoca in range(epocas):
        for i, x in enumerate(X):
            condicion_margen = Y[i] * (np.dot(x, w) + b) >= 1
            if condicion_margen:
                w = w - lr * (2 * lamda * w)
            else:
                w = w - lr * (2 * lamda * w - np.dot(Y[i], x))
                b = b - lr * lamda * Y[i]

    tolerancia = 0.9
    vectores_soporte_indices = [
        i for i, x in enumerate(X)
        if abs(Y[i] * (np.dot(x, w) + b) - 1) <= tolerancia
    ]
    vectores_soporte = X[vectores_soporte_indices]

    return w, b, vectores_soporte, vectores_soporte_indices

def prediccion_MSV(X_test, w, b):
    return np.sign(np.dot(X_test, w) + b)

# Cargar los datos
```

```
ruta_archivo = './train.csv'
datos = pd.read_csv(ruta_archivo)

Y = datos['Survived'].tolist()
vivos = [y for y in Y if y == 1][:30]
muertos = [y for y in Y if y == 0][:30]
Y_fixed = np.array(vivos + muertos)

indices_vivos = [i for i, y in enumerate(Y) if y == 1][:30]
indices_muertos = [i for i, y in enumerate(Y) if y == 0][:30]
indices_filtrados = indices_vivos + indices_muertos

SibSp = datos['SibSp'].tolist()
Age = datos['Age'].tolist()
Pclass = datos['Pclass'].tolist()

moda_sibsp = max(set(SibSp), key=SibSp.count)
SibSp = [moda_sibsp if pd.isna(s) else s for s in SibSp]
SibSp = [moda_sibsp if s < 0 or not isinstance(s, int) else s for s in
SibSp]
SibSp = [int(s) for s in SibSp]

Age = [np.nan if pd.isna(a) else a for a in Age]
promedio_edad = np.nanmean(Age)
Age = [promedio_edad if np.isnan(a) else a for a in Age]

moda_clase = max(set(Pclass), key=Pclass.count)
Pclass = [moda_clase if pd.isna(c) else c for c in Pclass]
Pclass = [int(c) for c in Pclass]

X = np.array(list(zip(Pclass, Age, SibSp)))
X_fixed = X[indices_filtrados]

w, b, vectores_soporte, vectores_soporte_indices =
entrenamiento_MSV(X_fixed, Y_fixed)

# Solicitar un nuevo punto al usuario
nuevo_punto = []
nuevo_punto.append(int(input("Ingrese la clase de pasajero (Pclass, 1-3):
")))
nuevo_punto.append(float(input("Ingrese la edad del pasajero: ")))
nuevo_punto.append(int(input("Ingrese el número de hermanos/esposos (SibSp):
")))

nuevo_punto = np.array(nuevo_punto)
clase_predicha = prediccion_MSV(nuevo_punto, w, b)

# Mostrar en terminal
resultado = "Sobrevivió" if clase_predicha == 1 else "No sobrevivió"
print(f"El nuevo punto pertenece a la clase: {resultado}")

# Gráfica tridimensional
```

```
fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(111, projection='3d')

# Graficar los datos
ax.scatter(X_fixed[:, 0], X_fixed[:, 1], X_fixed[:, 2], c=Y_fixed,
cmap=plt.cm.Paired, label='Datos')

# Graficar vectores de soporte
ax.scatter(X_fixed[vectores_soporte_indices, 0],
           X_fixed[vectores_soporte_indices, 1],
           X_fixed[vectores_soporte_indices, 2],
           s=150, facecolors='yellow', edgecolors='red', linewidths=2,
label='Vectores de Soporte')

# Graficar el nuevo punto
ax.scatter(nuevo_punto[0], nuevo_punto[1], nuevo_punto[2],
           color='green', marker='o', s=150, label='Nuevo punto')

# Generar un rango para los planos
x = np.linspace(X_fixed[:, 0].min(), X_fixed[:, 0].max(), 10)
y = np.linspace(X_fixed[:, 1].min(), X_fixed[:, 1].max(), 10)
x, y = np.meshgrid(x, y)

# Hiperplano: z = -(w[0]*x + w[1]*y + b) / w[2]
z = -(w[0] * x + w[1] * y + b) / w[2]

# Márgenes: z = -(w[0]*x + w[1]*y + b ± 1) / w[2]
z_margen_superior = -(w[0] * x + w[1] * y + (b + 1)) / w[2]
z_margen_inferior = -(w[0] * x + w[1] * y + (b - 1)) / w[2]

# Graficar el hiperplano y los márgenes
ax.plot_surface(x, y, z, alpha=0.3, color='blue', label='Hiperplano')
ax.plot_surface(x, y, z_margen_superior, alpha=0.2, color='green',
label='Margen Superior')
ax.plot_surface(x, y, z_margen_inferior, alpha=0.2, color='red',
label='Margen Inferior')

ax.set_xlabel('Pclass')
ax.set_ylabel('Age')
ax.set_zlabel('SibSp')
plt.title('Máquinas de Soporte Vectorial (MSV)')
plt.legend()
plt.show()
```

ALGORITMO SVM PÁTRONES DE IMÁGENES

```
import numpy as np
import matplotlib.pyplot as plt

# Entrenamiento SVM
def entrenamiento_MSV(X, Y):
    numero_muestras, numero_caracteristicas = X.shape
```

```
    # Inicialización parámetros externos
    epocas = 1000
    lr = 0.0001
    lamda = 1 / epocas

    # Inicialización de parámetros internos
    w = np.zeros(numero_caracteristicas) + 0.1
    b = 0.1

    for epoca in range(epocas):
        for i, x in enumerate(X):
            condicion_margen = Y[i] * (np.dot(x, w) + b) >= 1
            if condicion_margen:
                # Actualización mínima para alejar w del margen
                w = w - lr * (2 * lamda * w)
            else:
                w = w - lr * (2 * lamda * w - np.dot(Y[i], x))
                b = b - lr * lamda * Y[i]

    # Identificar vectores de soporte considerando ambos márgenes
    tolerancia = .00001
    vectores_soporte_indices = [
        i for i, x in enumerate(X)
        if abs(Y[i] * (np.dot(x, w) + b) - 1) <= tolerancia
    ]
    vectores_soporte = X[vectores_soporte_indices]

    return w, b, vectores_soporte, vectores_soporte_indices

# Predicción SVM
def prediccion_MSV(X_test, w, b):
    return np.sign(np.dot(X_test, w) + b)

# Función para visualizar patrones
def visualize_patterns(patterns, title):
    num_patterns = len(patterns)
    fig, axs = plt.subplots(1, num_patterns, figsize=(12, 6))
    if num_patterns == 1:
        axs = [axs]
    for i in range(num_patterns):
        axs[i].imshow(patterns[i], cmap='gray')
        axs[i].axis('off')
    plt.suptitle(title)
    plt.show()
```

```
# Definición manual de los patrones base
base_T = np.zeros((10, 10))
base_T[1, 2:8] = 1
base_T[2:9, 5] = 1

base_J = np.zeros((10, 10))
base_J[1:9, 5] = 1
base_J[8, 3:6] = 1
base_J[7:9, 3] = 1

# Generación manual de variaciones de los patrones
patterns_T = [base_T + np.random.uniform(-0.05, 0.05, base_T.shape) for _ in
range(20)]
patterns_J = [base_J + np.random.uniform(-0.05, 0.05, base_J.shape) for _ in
range(20)]

# Generación de patrones ruidosos adicionales
noisy_patterns_T = [
    base_T + np.random.uniform(-0.05, 0.05, base_T.shape) for _ in range(3)
]
noisy_patterns_J = [
    base_J + np.random.uniform(-0.05, 0.05, base_J.shape) for _ in range(3)
]

# Aplicar SVD a todos los patrones
dimensiones = 5
X = []

for pattern in patterns_T + patterns_J:
    U, S, Vt = np.linalg.svd(pattern)
    X.append((U[:, :dimensiones] @ np.diag(S[:dimensiones])).flatten())

X = np.array(X)
Y = np.array([-1] * 20 + [1] * 20)  # Clases: -1 para T, 1 para J

# Representaciones de los patrones ruidosos
U_T, S_T, _ = np.linalg.svd(noisy_patterns_T[0])
test_T = (U_T[:, :dimensiones] @ np.diag(S_T[:dimensiones])).flatten()

U_J, S_J, _ = np.linalg.svd(noisy_patterns_J[0])
test_J = (U_J[:, :dimensiones] @ np.diag(S_J[:dimensiones])).flatten()

# Entrenamiento con SVM
w, b, vectores_soporte, vectores_soporte_indices = entrenamiento_MSV(X, Y)
```

```
# Predicción
clase_T = prediccion_MSV(test_T, w, b)
clase_J = prediccion_MSV(test_J, w, b)

print("Clase para el patrón T (ruido):", "T" if clase_T == -1 else "J")
print("Clase para el patrón J (ruido):", "T" if clase_J == -1 else "J")

# Visualización
visualize_patterns([base_T], "Patrón Base T")
visualize_patterns([base_J], "Patrón Base J")
visualize_patterns(patterns_T, "Variaciones de Patrón T")
visualize_patterns(patterns_J, "Variaciones de Patrón J")
visualize_patterns([noisy_patterns_T[0]], f"Patrón Ruido T - Clasificado
como {'T' if clase_T == -1 else 'J'}")
visualize_patterns([noisy_patterns_J[0]], f"Patrón Ruido J - Clasificado
como {'T' if clase_J == -1 else 'J'}")
visualize_patterns([noisy_patterns_T[1]], f"Patrón Ruido T - Clasificado
como {'T' if clase_T == -1 else 'J'}")
visualize_patterns([noisy_patterns_J[1]], f"Patrón Ruido J - Clasificado
como {'T' if clase_J == -1 else 'J'}")
visualize_patterns([noisy_patterns_T[2]], f"Patrón Ruido T - Clasificado
como {'T' if clase_T == -1 else 'J'}")
visualize_patterns([noisy_patterns_J[2]], f"Patrón Ruido J - Clasificado
como {'T' if clase_J == -1 else 'J'}")
```

b) Funcionamiento

ALGORITMO SVM CON PROBLEMÁTICA DEL TITANIC

De manera similar al caso del Titanic con la implementación del algoritmo K-means++, se solicita al usuario ingresar un nuevo dato para clasificar, y el sistema imprime en la terminal si la persona sobrevivió o falleció, basándose en el entrenamiento previo.

Para el caso de las Máquinas de Vectores de Soporte (SVM), se llevó a cabo un entrenamiento equilibrado utilizando un conjunto de datos compuesto por 30 personas fallecidas y 30 sobrevivientes. Este equilibrio fue fundamental para garantizar una clasificación adecuada, ya que este algoritmo se basa en la separación de valores binarios. Además, fue necesario emplear una gráfica tridimensional para visualizar y analizar mejor los resultados de la clasificación.

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS  GITLENS  COMMENTS

PS C:\Users\gonza\OneDrive\Documentos\Octavo Semestre\Machine Learning> python titanic-MSV.py
Ingrese la clase de pasajero (Pclass, 1-3): 1
Ingrese la edad del pasajero: 4
Ingrese el número de hermanos/esposos (SibSp): 3
El nuevo punto pertenece a la clase: Sobrevivió
```

Figura. *Resultado en terminal de una persona que sobrevivió. Fuente: Elaboración propia.*

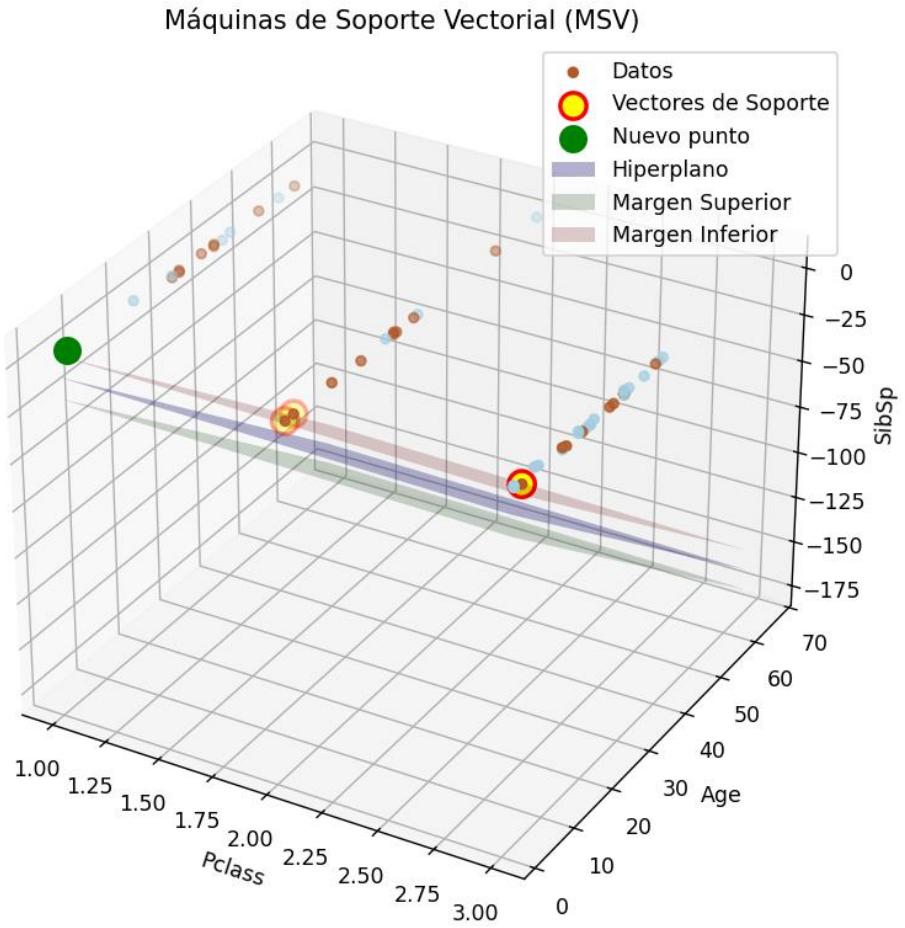

Figura. *Resultado en gráfica 3D de una persona que sobrevivió. Fuente: Elaboración propia.*

ALGORITMO SVM PÁTRONES DE IMÁGENES

En este ejercicio, trabajamos con dos patrones de datos que forman las letras "T" y "J". Generamos diversas variaciones de estos patrones con el propósito de entrenar el modelo y así clasificar correctamente dos nuevos patrones para cada letra. Para esta tarea, empleamos Máquinas de Vectores de Soporte (SVM), lo que nos permitió determinar a qué clase pertenece cada uno de los nuevos patrones propuestos, basándonos en las características aprendidas durante el entrenamiento.

En las siguientes figuras se muestra la manera la clasificación realizada por el algoritmo con los nuevos patrones implementados.

Patrón Base T

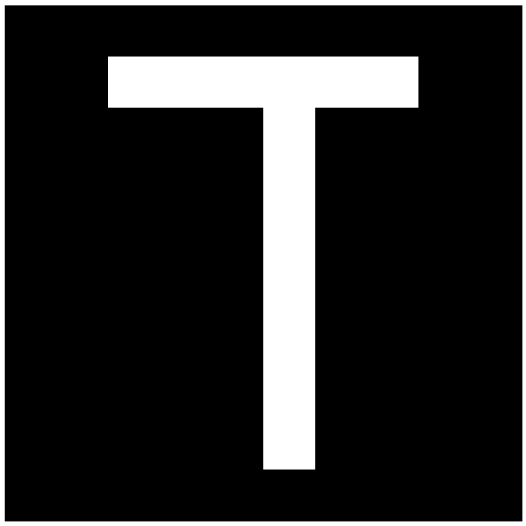

Patrón Base J

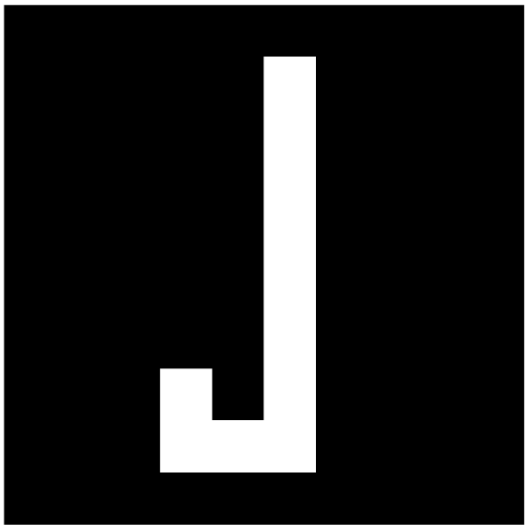

Patrón Ruido T - Clasificado como T

Patrón Ruido J - Clasificado como J

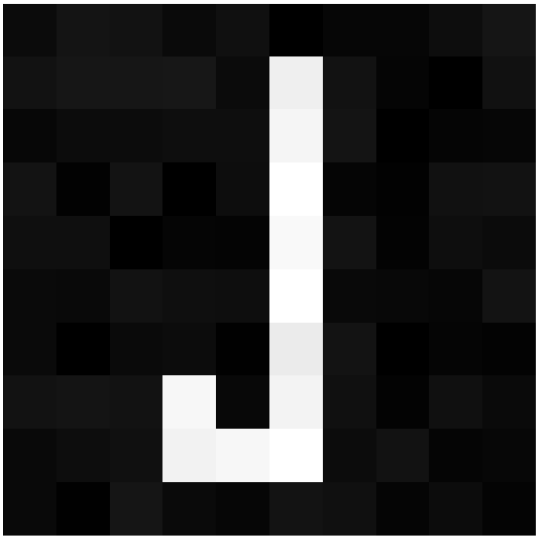

2.3. CONCLUSIÓN

En el caso del algoritmo SVM, es fundamental que el programador analice cuidadosamente los datos y las características del conjunto para seleccionar los parámetros adecuados, como el kernel y los valores de regularización. Una elección incorrecta de estos parámetros puede comprometer significativamente la capacidad del algoritmo para clasificar los datos de manera precisa.

Por ejemplo, si los datos no son linealmente separables y se selecciona un kernel lineal en lugar de uno no lineal, como el RBF o el polinomial, el modelo podría fallar en capturar las relaciones complejas presentes en los datos. Este escenario destaca la importancia de una exploración visual y un análisis detallado de los datos antes de entrenar el modelo.

Al igual que con otros algoritmos, el éxito de SVM depende tanto de las decisiones tomadas durante la configuración como de la calidad del conjunto de datos, lo que subraya la relevancia de combinar el conocimiento técnico con una comprensión profunda de los datos para garantizar resultados óptimos.